

Bericht

Alisa Pesteritz, Saliha Altan, Wiktorja Cholewa,
Dominik Falk, Andreas Kasarinow, Johanna Kleidorfer,
Adrika Narasimhan, Rosina Röckseisen

16. Juli 2026

1 Einleitung

2 Grundlagen

2.1 Biologische Grundlagen

2.1.1 Genexpression und -regulation

Die im Folgenden analysierten Genexpressionsdaten beschreiben die Aktivität eines Gens und damit, wann und in welcher Intensität ein Gen abgelesen wird. Dies entscheidet über den Phänotyp einer Zelle, denn auch wenn die Zellen eines Organismus dieselbe genetische Information in Form von DNA enthalten, erfüllen sie doch sehr unterschiedliche Funktionen. Die Genexpression folgt dabei dem Zentralen Dogma der Molekularbiologie, bei der Transkription wird die in der DNA kodierte Information in RNA und anschließend mittels der Translation in Proteine überführt [13].

Dieser Prozess der Genexpression unterliegt einer zellinternen Genregulation. Dabei binden Transkriptionsfaktoren an regulatorische DNA-Abschnitte wie Promotoren und Enhancer und rekrutieren darüber die RNA-Polymerase, welche das Ablesen des jeweiligen Genabschnitts startet. Je nach gebundenem Transkriptionsfaktor wird die Transkription gehemmt oder aktiviert, es kommt also entweder zum Ablesen oder nicht. Transkriptionsfaktoren sind dabei selbst Proteine, die als Genprodukte anderer Gene entstehen. Je nach Zelltyp, Entwicklungsstadium und äußeren Signalen sind verschiedene Transkriptionsfaktoren vorhanden und aktiv. Diese kaskadierenden Genregulationsnetzwerke erklären, warum trotz identischer DNA in jeder Zelle andere Gene ausgelesen werden [13].

Die Feinjustierung der Genexpression umfasst mehrere nachgelagerte Ebenen. Post-transkriptionell wird beispielsweise durch microRNAs oder alternatives Spleißen reguliert, diese Prozesse entscheiden welche und wie viel mRNA für die Translation zur Verfügung steht. Translational wird die Proteinbiosyntheserate kontrolliert, welche bestimmt, wie viele funktionale Proteine aus einer gegebenen mRNA-Menge tatsächlich entstehen. In der post-translationalen Ebene findet schließlich die Proteinmodifikation (z. B. Phosphorylierung, Ubiquitinierung) statt. Eine Abnormalität in einer dieser Kontrollebenen kann zur Fehlregulation der Genexpression und infolgedessen zu Krankheitsbildern führen [13].

Die Datenerhebung der möglicherweise dafür verantwortlichen RNA-Mengen erfolgt nach heutigem Stand der Technik meist über das High-Throughput-Verfahren des Next-Generation-Sequencing (RNA-Seq). In Ausnahmefällen werden noch ältere Microarray-Technologien verwendet, diese haben allerdings eine geringere Sensitivität und einen eingeschränkteren dynamischen Messbereich als RNA-Seq [22]. Der bioinformatische Workflow führt dabei von der RNA-Isolation über das Alignment an ein Referenzgenom bis hin zur Generierung einer rohen Count-Matrix [11]. Diese Matrix bildet das Ergebnis der Sequenzierung ab, sie enthält für jedes Gen (Zeilen) und jede untersuchte Probe oder jeden Patienten (Spalten) die Anzahl der Reads. Ein solches tabellarische Format erwartet auch der CSV-Upload des, in diesem Projekt entwickelten Dashboards (siehe Kap. 7).

Bei diesen Rohdaten kommt es jedoch unweigerlich zu systematischen Verzerrungen, bedingt durch variierende Genlängen und stark schwankende Sequenziertiefen zwischen den einzelnen Probenläufen. Die Sequenziertiefe bezeichnet dabei die Gesamtzahl der in einem Lauf erzeugten Reads für eine Probe und kann zwischen den Proben stark variieren. Ein direkter Vergleich zweier Proben unterschiedlicher Sequenziertiefen würde also fälschlicherweise einen Unterschied in der Genaktivität suggerieren, obwohl dieser lediglich an der Datenmenge liegt. Für eine valide biologische Vergleichbarkeit müssen die Datensätze daher zwingend mathematisch normalisiert werden, bevor sie miteinander verglichen werden können (siehe Kap. 5) [16].

Die Analyse der Genexpressionsdaten ist vorrangig für die Onkologie von großem Interes-

se. Dabei wird die Genaktivität quantifiziert und analysiert, wofür das Transkriptom, also die Gesamtheit aller zu einem bestimmten Zeitpunkt in einer Zelle transkribierten RNA-Moleküle, betrachtet werden muss [1]. Denn nicht nur das Genom, also die strukturelle DNA und deren Mutationen, ist entscheidend für die Entstehung und das Fortschreiten vieler Krankheitsbilder, sondern maßgeblich auch die zelluläre Aktivität. So lassen sich beispielsweise pathophysiologische Prozesse wie unkontrolliertes Zellwachstum oder die Metastasierung bei strukturell intakten Genen beobachten, wenn diese fehlerhaft reguliert (über- oder unterexprimiert) sind [21].

Zu berücksichtigen ist dabei außerdem, dass Genexpression kein synchroner, sondern ein zeitlich gestaffelter, asynchroner Prozess ist. Wird eine Zelle beispielsweise durch einen Wachstumsfaktor oder eine DNA-Schädigung stimuliert, werden nicht alle beteiligten Gene gleichzeitig abgelesen. Zuerst reagieren einzelne, meist regulatorisch wirkende Gene innerhalb weniger Minuten, deren Genprodukte wiederum weitere, nachgeschaltete Zielgene erst zeitversetzt aktivieren [13]. Eine einzelne RNA-Seq-Messung bildet dabei stets nur eine Momentaufnahme dieses dynamischen Prozesses ab. Zwei Gene, die demselben biologischen Signalweg angehören, müssen in einer solchen Momentaufnahme also nicht zwangsläufig ein gleich starkes Expressionsniveau aufweisen.

2.1.2 Pathways und die KEGG-Datenbank

Da viele biologische Prozesse jedoch nicht monogen ablaufen, reicht die Betrachtung einzelner Gene meist nicht für die biologische Interpretierbarkeit. Deshalb müssen funktionell zusammenhängende Gene gemeinsam betrachtet werden, um Muster und Zusammenhänge erkennen zu können. Dementsprechend ist es wichtig die Gene zusammen darzustellen, welche an denselben biologischen Signalwegen beteiligt sind, dies kann durch sogenannte Pathways realisiert werden. Dabei handelt es sich um kuratierte Netzwerke von Genen bzw. Genprodukten, die gemeinsam einen gewissen Signalweg abbilden, wie beispielsweise den einer Signaltransduktion. Die Pathways reduzieren für die Analyse der Daten die Komplexität und erhöhen dabei gleichzeitig die Interpretierbarkeit der Ergebnisse, da sie den funktionalen Kontext liefern [10].

Eine der wichtigsten Referenzdatenbanken, welche hunderte dieser kuratierten Pathways für unterschiedlichste Organismen bereithält, ist die Kyoto Encyclopedia of Genes and Genomes (KEGG) [9]. KEGG bildet Signalwege, Stoffwechselwege und krankheitsassoziierte Prozesse als standardisierte grafische annotierte Netzwerke ab und beinhaltet pro Pathway die zusammengehörigen Gene. Damit können die Genexpressionsdaten direkt auf die bekannten biologischen Zusammenhänge abgebildet werden.

Das in diesem Projekt entwickelte Dashboard erlaubt es den Nutzern verschiedenste Pathways der KEGG-Datenbank auszuwählen. Damit lässt sich die Analyse gezielt auf die für einen bestimmten Signalweg relevanten Gene eingrenzen, anstatt anstatt alle in der Count-Matrix enthaltenen Gene gemeinsam betrachten zu müssen. Genauer zur technischen Implementierung ist in Kapitel 4 zu finden.

2.2 Medizinische Grundlagen

2.2.1 Klinische Relevanz der Genexpressionanalyse

Das entwickelte Tumorboard-Dashboard findet vorrangig im klinischen Kontext, bei der Entwicklung personalisierter Therapiepläne, Anwendung. Ärzte sind hierbei besonders an der Genexpression und deren Regulation interessiert, da herkömmliche histopathologische, also rein visuelle Untersuchungen des Tumorgewebes die molekulare Heterogenität von Tumoren meist nicht vollständig abbilden können [21]. Denn zwei histologisch identische Tumore können auf molekularer Ebene vollkommen unterschiedliche Aktivitätsprofile aufweisen und entsprechend

unterschiedlich auf verschiedene Therapien ansprechen. Diese Informationsebene kommt im klinischen Bereich besonders für die Diagnosen, die Prognoseabschätzung und die Vorhersage der Erfolgschancen bei Therapieansätzen zum Einsatz [15]. Beispiele aus der heutigen Zeit für den Einsatz der Genexpressionsdaten sind die Bestimmung des Ursprungsgewebes bei Tumoren unbekannter Herkunft, die Therapieentscheidung bei Brustkrebs sowie die Einschätzung des Rezidivrisikos, also der Wahrscheinlichkeit, dass die Erkrankung nach erfolgreicher Genesung erneut auftritt [15].

2.2.2 Das Molekulare Tumorboard

Das Molekulare Tumorboard (MTB) ist eine interdisziplinäre Expertenkonferenz, in der für besondere Krankheitsbilder oder spezielle Verläufe individualisierte Therapiepläne entwickelt werden. Hier dienen die genomischen und transkriptomischen Profile der Entscheidungsfindung [19].

2.2.3 Das Dashboard als Clinical Decision Support System

Das Dashboard fungiert hierbei als interaktives Clinical Decision Support System (CDSS) [19]. Es bietet mit der Heatmap und den Dendrogrammen eine gemeinsame, leicht verständliche, visuell dargestellte Diskussionsgrundlage für die beteiligten Experten. Es erlaubt einem interdisziplinären Kollektiv aus Onkologen, Pathologen, Chirurgen und Bioinformatikern die medizinischen Analysen ohne Programmierkenntnisse in Echtzeit über eine grafische Benutzeroberfläche zu steuern und anschließend gemeinsam darüber zu beraten.

Das Ziel des interdisziplinären Gremiums besteht dementsprechend darin, die genomischen und transkriptomischen Profile der Patienten mithilfe des CDSS gemeinschaftlich zu evaluieren und mit den daraus generierten Informationen eine individuelle Therapieempfehlung auszuarbeiten. Denn wichtige und weitreichende Therapieentscheidungen können nicht von einem einzelnen Arzt isoliert verantwortet werden [14]. Studien belegen, dass diese Art der computergestützten Therapiewahl die Behandlungsergebnisse maßgeblich verbessern kann [8]. Durch die Anpassungsmöglichkeiten, wie die Auswahl spezifischer biologischer Pathways, die Modifikation der Normalisierungsverfahren, die Wahl des Cluster-Algorithmus (z. B. Single, Average und Complete Linkage) und der farblichen Darstellung kann das Dashboard zum zentralen Visualisierungsmedium in der Konferenz werden. Das ermöglicht den Ärzten, Hypothesen direkt während der Sitzung gemeinsam zu prüfen, molekulare Muster im Kollektiv zu interpretieren und so die bestmögliche personalisierte Therapieempfehlung für die Patienten auszuarbeiten [17].

2.2.4 Informatische Grundlagen

Was ist eine explorative Datenanalyse?

Was ist Clustering?

3 Arbeitseinteilung (oder sowas)

4 Pathways und Dateneinlesen

Die Tabelle zeigt, wie groß der Arbeitsaufwand pro Unteraufgabe ausgefallen ist.

Aufgabe	Zuständig	Arbeitsaufwand
Recherche zu Pathways und Extraktion der Daten von KEGG	Alisa	5 Stunden
Datenbank entwerfen und aufsetzen	Alisa	7 Stunden
Funktionen: Prozessierung, Datenbankabfragen und Integration	Alisa	17 Stunden
Datensätze bearbeiten	Alisa	5 Stunden
Besprechungstermine	Alle	19,5 Stunden
Berichterstellung	Alisa	5 Stunden

Der Bereich Pathways und Dateneinlesen untergliedert sich in mehrere Teilbereiche, welche im Folgenden näher erläutert werden.

4.1 Datenbeschaffung

Das zentrale Ziel des Aufgabenbereiches war die semantische Datenintegration biologischer Genexpressionsdatensätze. Konkret sollte es möglich sein, aus einem größeren Genexpressionsdatensatz, gezielt die Gene herauszufiltern, die den vom Nutzer ausgewählten biologischen Pathways zugeordnet sind. Voraussetzung dafür ist eine strukturelle Grundlage für die Verknüpfung der Pathways mit ihren zugehörigen Genen. Dafür wurde die KEGG-Datenbank verwendet, welche im Abschnitt 2.1 zusammen mit der Funktion der Pathways näher erläutert wird. KEGG stellt eine öffentliche REST-API-Schnittstelle bereit, über die die folgende Informationen abgerufen und als CSV-Dateien gespeichert wurden:

- Pathway-Liste: Alle menschlichen Pathways mit ihrer KEGG ID und ihrem Namen. Abgerufen über <https://rest.kegg.jp/list/pathway/hsa>.
- Gen-Pathway Verknüpfungen: Die Zuordnung von Genen zu ihren entsprechenden Pathways. Abgerufen über <https://rest.kegg.jp/link/pathway/hsa>.

Die CSV-Dateien wurden anschließend in R bereinigt. Präfixe wie `path:` und `Homo sapiens` wurden entfernt, um nur die relevanten Informationen abzubilden.

Da über die KEGG-API nur Entrez IDs und keine Gennamen bereitgestellt wurden, mussten die zugehörigen Gennamen nachträglich gemappt werden. Hierzu wurden über die Annotationsbibliothek `org.Hs.eg.db` gezielt die Entrez IDs mit den entsprechenden Gennamen verknüpft, die in den abgerufenen Pathways enthalten sind.

4.2 Aufbau der lokalen SQLite Datenbank

Auf Basis der KEGG-Daten sowie der Zuordnung von Entrez IDs zu Gennamen wurde eine lokale SQLite-Datenbank "`GeneDatabase.sqlite`" aufgebaut. Diese dient als semantisches Bindeglied zwischen den Genexpressionsdatensätzen und den Pathways. Die Entscheidung für eine relationale Datenbank fiel aufgrund des deutlich effizienteren Datenzugriffs im Vergleich zu CSV- oder Excel-Dateien. Die daraus resultierende Datenbank besteht aus drei Tabellen:

- Gene: Enthält die Entrez ID als Primärschlüssel, den vollständigen Gennamen sowie das Gensymbol
- Pathway: Enthält die KEGG- Pathway ID und den Namen des Pathways.

- `Lookup_Gene_Pathway`: Stellt eine N:M Relation zwischen Genen und Pathways dar.




Abbildung 1: Eigene Darstellung: ERM Modell zum Aufbau der Datenbank

4.3 Funktionen zur Datenvorverarbeitung und Datenintegration

Die gesamte Programmlogik ist modular aufgebaut und gliedert sich funktional in vier zentrale Aufgabenbereiche: Datenvorverarbeitung zur Metadaten-Trennung, Coverage Analyse, Datenbankabfragen sowie die finale Datenintegration. Es existieren zwei spezialisierte Vorverarbeitungsfunktionen, die je nach Datentyp der ersten Spalte des Datensatzes aufgerufen werden: `preprocess_dataset_meta()` extrahiert numerische Entrez IDs, während `preprocess_dataset_meta_gennames()` genutzt wird, wenn Gennamen als `character` vorliegen. Beide Funktionen implementieren die Trennung von Messwerten und Metadaten über die Identifikation des Präfixes (`Meta_.`). Dies ermöglicht es die Metainformationen separat von den eigentlichen Genexpressionsdaten zu speichern, sodass andere Teammitglieder für ihre Teilaufgaben direkt darauf zugreifen können.

4.3.1 Pathway Coverage

Bevor die eigentliche Datenintegration durchgeführt wird, kann mit der Funktion `analyze_pathways_coverage()` geprüft werden, wie gut die vom User ausgewählten Pathways durch den hochgeladenen Datensatz abgedeckt werden. Für jeden gewählten Pathway wird anhand einer Datenbankabfrage ermittelt, wie viele der in der Datenbank hinterlegten Gene im Datensatz vorhanden sind und wie viele fehlen. Die Funktion gibt eine Matrix mit den Spalten Gesamtanzahl, gefundene Gene, fehlende Gene sowie der prozentualen Abdeckung (Coverage) zurück. Diese Funktion dient als wichtige Entscheidungsgrundlage, um die Aussagekraft der nachfolgenden Analysen zu bewerten. Bei einer unzureichenden Abdeckung erhält der Nutzer somit die Möglichkeit, die Pathway Auswahl frühzeitig zu optimieren.

4.3.2 Datenintegration

Die Kernfunktion `run_data_integration()` verbindet alle Hilfsfunktionen und führt die semantische Filterung der Daten nach ausgewählten Pathways durch. Der Ablauf ist wie folgt:

- Der Datensatz wird anhand des Datentyps der ersten Spalte mit der passenden Funktion vorverarbeitet und von den Metadaten separiert.

- Über Datenbankabfragen werden alle relevanten Gene ermittelt, die den vom Nutzer gewählten Pathways zugeordnet sind. Es werden sowohl die IDs als auch die zugehörigen Gennamen in Vektoren gespeichert.
- Mittels der Funktion `extract_relevant_genes()` wird der Datensatz auf diese Gene reduziert. Werden keine Übereinstimmungen gefunden, bricht der Prozess mit einer Fehlermeldung ab.
- Die Funktion `rename_duplikate_genes()` behandelt mehrfach vorhandene IDs und macht sie über ein Suffix eindeutig (z. B. "51_1", "51_2"). Durch diese Eindeutigkeit können die IDs nun als Zeilennamen verwendet werden.
- Als Ergebnis wird eine benannte Liste zurückgegeben, die den gefilterten Datensatz, die Metadaten, den Genvektor sowie die zugehörigen Gennamen enthält.

4.4 Datensätze

Zum Testen der implementierten Funktionen wurden vier Genexpressions-Datensätze bereitgestellt. Zwei dieser Datensätze stammen aus dem TCGA-Register.

The Cancer Genome Atlas (TCGA) ist ein großes, öffentliches Forschungsprogramm, welches umfassende genomische Daten und klinische Metadaten von über 33 verschiedenen Krebsarten bereitstellt [?].

Zwei der für dieses Projekt verwendeten Testdatensätze stammen aus diesem Programm:

- **colon_vs_pancreas_meta.csv**: Datensatz, der Proben von Darm- und Bauchspeicheldrüsenkrebs vergleicht.
- **TCGA_kidney_unnormalized_meta.csv**: Datensatz, der die drei Nierenkrebs-Unterarten: papilläres, chromophobes und klarzelliges Nierenzellkarzinom enthält.

Ein weiterer zur Verfügung gestellter Datensatz ist der Golub-Datensatz: **GOLUB_microarray.csv**. Dieser enthält Genexpressionsdaten, die genutzt wurden, um Patienten mit zwei verschiedenen Arten von Blutkrebs zu klassifizieren: der akuten myeloischen Leukämie und der akuten lymphatischen Leukämie [6].

Der letzte zur Verfügung gestellte Datensatz ist der SHIPP-Datensatz: **SHIPP_microarray.csv**. Dieser enthält zwei Formen von Non-Hodgkin-Lymphomen: das diffuse großzellige B-Zell-Lymphom und das folliculäre Lymphom [18].

Die Datensätze wurden nach einem einheitlichen Schema aufbereitet und für alle Teammitglieder bereitgestellt: Während die erste Spalte immer die numerischen Entrez IDs oder Gennamen enthält, repräsentieren die darauffolgenden Spalten die einzelnen Patientenproben. Zur Erweiterung der Metadaten wurden für alle Datensätze zufällige Werte für Alter und Geschlecht generiert. Um die Metadaten sauber von den eigentlichen Genexpressionsdaten zu trennen, wurden diese einheitlich mit dem Präfix **Meta_** versehen.

5 Normalisierung

5.1 Berechnung der Distanzmatrix

Für das Zusammenfügen der Cluster muss zunächst bestimmt werden, wie ähnlich, bzw. nah diese zueinander sind. Da es sich bei den in diesem Projekt verwendeten Genexpressionsdaten um kontinuierliche Daten handelt, wird ihre Nähe mit Hilfe von Distanzmaßen bestimmt. Für ein Distanzmaß δ_{ij} muss die Dreiecksungleichung gelten, d.h. für drei Elemente i , j und m :

$$\delta_{ij} + \delta_{im} \geq \delta_{jm}$$

Durch Berechnen der zeilenweisen Distanzen δ_{ij} , für welche diese Bedingung gilt, entsteht eine symmetrische Distanzmatrix **D**, wobei $\delta_{ii} = 0$ für alle i gilt [4]. Es muss sowohl eine Distanzmatrix für die Gene als auch für die Patienten berechnet werden. Im zweiten Fall wird der Datensatz zunächst transponiert, so dass zeilenweise gearbeitet werden kann.

Es gibt eine Vielzahl an Distanzmaßen, die verwendet werden können. In dem Projekt wurden die folgenden sechs Distanzfunktionen implementiert: euklidische Distanz, Manhattan-Distanz, Minkowski-Distanz, Canberra-Distanz, Pearson-Korrelation und Winkeldistanz (Angular Separation). Eine Übersicht der Distanzfunktionen befindet sich in Tabelle 1. Hierbei sind x_{ik} und x_{jk} jeweils die k -te Variablen der p -dimensionalen Beobachtungen der Variablen i und j . Die Auswahl entstammt Everitt et al. [4], verzichtet allerdings auf Gewichte.

Die euklidische Distanz (D1) gilt häufig als das gängigste Distanzmaß. Sie hat die Eigenschaft, dass die berechnete Distanz als ein Abstand zwischen zwei Punkten im p -dimensionalen Raum verstanden werden kann [4]. Die Manhattan-Distanz (D2) ist ähnlich, definiert den Abstand allerdings ausschließlich über geradlinige Verbindungen. D1 und D2 sind Spezialfälle der Minkowski-Distanz (D3), für $r = 2$, bzw. $r = 1$. Dem Nutzer wird bei Auswahl von D3 die Möglichkeit gegeben, einen eigenen Wert für r einzugeben, wobei Werte < 1 nicht zulässig sind.

Die Canberra-Distanz (D4) ist besonders sensitiv für kleine Veränderungen nahe 0 [4].

Mit D5 und D6 stehen auch zwei Korrelationsmaße als Distanzfunktionen zur Verfügung. Für die Korrelation ϕ_{ij} gilt $-1 \leq \phi_{ij} \leq 1$, wobei 1 die größte positive Korrelation und -1 die größte negative Korrelation darstellt. Die Korrelation kann in eine Distanz δ_{ij} im Intervall $[0, 1]$ umgerechnet werden. Korrelationsmaße eignen sich für Daten, die auf der gleichen Skala gemessen wurden, sowie deren exakten Werte nur insofern von Interesse sind, als sie Aufschluss über das relative Profil geben. So hat z.B. die Winkeldistanz (D6) die Eigenschaft, dass nur dann eine minimale Distanz von 0 zwischen zwei Zeilen entsteht, wenn die Werte der einen Zeilen Mehrfache der Werte der anderen Zeile sind.

Im Projekt wurde eine gemeinsame Funktion für die Berechnung der Distanzmatrix in C++ implementiert. Dafür wurde ein separates Repository erschaffen. Das Paket **Rcpp** [3] ermöglicht die Einbindung des C++-Codes in eine R-Umgebung. Die eigentliche Funktion heißt **dist_cpp** und bekommt drei Parameter übergeben: eine numerische Matrix **mat** (den normalisierten Datensatz), einen String **method** für das gewählte Distanzmaß, und einen Integer **p**. Letzter entspricht dem Parameter r in der Minkowski-Distanz (D3). Die Implementierung entspricht den mathematischen Formeln und ist entsprechend einfach.

5.2 Linkagefunktionen

Die eigentliche Clusterung erfolgt mit der Linkage-Funktion **hierarchical_clustering**. Diese Funktion erhält als Parameter eine Distanzmatrix **d_mat** (siehe Kapitel 5.1), den Namen des gewünschten Linkage-Verfahrens **method** als String, sowie optional eine Liste mit vier Parametern **custom_params**. Standardmäßig wird als Methode **"single"** und für die Parameter NULL übergeben.

Nr.	Name	Funktion
D1	Euklidische Distanz	$d_{ij} = (\sum_{k=1}^p (x_{ik} - x_{jk})^2)^{1/2}$
D2	Manhattan-Distanz	$d_{ij} = \sum_{k=1}^p x_{ik} - x_{jk} $
D3	Minkowski-Distanz	$d_{ij} = (\sum_{k=1}^p x_{ik} - x_{jk} ^r)^{1/r}$ mit $r \geq 1$
D4	Canberra-Distanz	$d_{ij} = \begin{cases} 0 & \text{wenn } x_{ik} = x_{jk} = 0 \\ \sum_{k=1}^p x_{ik} - x_{jk} / (x_{ik} + x_{jk}) & \text{sonst} \end{cases}$
D5	Pearson-Korrelation	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})(x_{jk} - \bar{x}_{j\cdot})}{[\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})^2 \sum_{k=1}^p (x_{jk} - \bar{x}_{j\cdot})^2]^{1/2}},$ $\bar{x}_{i\cdot} = \frac{1}{p} \sum_{k=1}^p x_{ik}$
D6	Winkeldistanz	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p x_{ik} x_{jk}}{(\sum_{k=1}^p x_{ik}^2 \sum_{k=1}^p x_{jk}^2)^{1/2}}$

Tabelle 1: Implementierte Distanzmaße

Das Ergebnis dieser Funktion ist eine Liste mit zwei Elementen, die für die Visualisierung der Ergebnisse benötigt werden. Das erste Element ist `matched_at`, ein Vektor, der die Werte enthält, an denen die Cluster zusammengefügt wurden. Dies entspricht der minimalen Distanz an jedem Schritt. Das zweite Element der Output-Liste ist `merge`, eine $n - 1$ mal 2 Matrix, die in jeder Zeile die zusammengeführten Cluster-Indizes enthält.

Als Methoden stehen Single-Linkage (`single`), Average-Linkage (`average`) und Complete-Linkage (`complete`), sowie eine benutzerdefinierte Linkage-Funktion (`custom`) zur Verfügung. Nach jeder Zusammenführung zweier Cluster wird die Distanzmatrix entsprechend der gewählten Linkage-Methode aktualisiert.

5.2.1 Linkagefunktion nach Lance-Williams

Die Methode `custom` implementiert die allgemeine Formel von Lance und Williams [12]. Werden zwei Cluster i und j zu einem neuen Cluster k zusammengefasst, so kann die Distanz des neuen Clusters k zu einem weiteren Cluster h durch diese Funktion aktualisiert werden:

$$d_{hk} = \alpha_i d_{hi} + \alpha_j d_{hj} + \beta d_{ij} + \gamma |d_{hi} - d_{hj}|$$

Die vier Parameter α_i , α_j , β und γ bestimmen die Aktualisierung der Distanz. Erst ihre jeweilige Kombination definiert ein konkretes Linkage-Verfahren, wie Single-, Complete- oder Average-Linkage. Tabelle 2 enthält eine Übersicht der erforderlichen Parameter für diese drei Standardverfahren.

Die Implementierung basiert vollständig auf dieser allgemeinen Formel. Dadurch kann die Aktualisierung der Distanzmatrix unabhängig vom konkreten Linkage-Verfahren mit derselben Implementierung erfolgen; lediglich die Parameter unterscheiden sich zwischen den Verfahren. Für die Methoden **single**, **average** und **complete** werden die zugehörigen Parameter automatisch gesetzt. Wird hingegen **custom** gewählt, müssen die vier Parameter vom Benutzer über die Eingabemaske angegeben werden. Die Eingabe wird lediglich auf numerische Werte überprüft. Dynamische Ausdrücke wie n_i/n_k , die beispielsweise für Average-Linkage verwendet werden, können daher nicht angegeben werden. Ebenso erfolgt keine Überprüfung hinsichtlich der theoretischen Sinnhaftigkeit der gewählten Parameter.

5.2.2 Bedeutung der Parameter

Die Parameter α_i und α_j gewichten den Beitrag der ursprünglichen Cluster i und j auf die neue Distanz d_{hk} . Gilt $\alpha_i = \alpha_j$, so werden beide Cluster gleich gewichtet, wie es bei Single- und Complete-Linkage der Fall ist. Beim Average-Linkage-Verfahren werden die Gewichte proportional zu der jeweiligen Clustergröße gewählt. Hierbei entsprechen n_i und n_j jeweils der Anzahl der Elemente im Cluster i , bzw. j . Es gilt $n_k = n_i + n_j$.

Der Parameter β gewichtet zusätzlich die Distanz d_{ij} zwischen den beiden zusammengeführten Clustern. Dadurch kann die Lage der neu berechneten Distanz beeinflusst werden. Für die drei implementierten Standardverfahren gilt $\beta = 0$, daher wirkt sich der Term nicht auf das Ergebnis aus. Lance und Williams diskutieren jedoch die zentrale Rolle dieses Parameters in der sogenannten *Flexiblen Strategie*, wobei β im Bereich $-1 \leq \beta < 1$ betrachtet wird, so dass weitere Linkage-Verfahren entstehen.

Der Parameter γ gewichtet die absolute Differenz zwischen d_{hi} und d_{hj} . Für die Werte $\gamma = -0,5$, bzw. $\gamma = 0,5$ reduziert sich die Lance-Williams-Formel auf das Minimum, bzw. das Maximum der beiden Distanzen. Dadurch erhält man unmittelbar Single-Linkage, bzw. Complete-Linkage. Für $\gamma = 0$ hingegen entfällt dieser Term vollständig, wie es z.B. beim Average-Linkage der Fall ist.

Linkage-Verfahren	α_i	α_j	β	γ	Eigenschaft
Single-Linkage	0,5	0,5	0	-0,5	Minimum
Complete-Linkage	0,5	0,5	0	0,5	Maximum
Average-Linkage	n_i/n_k	n_j/n_k	0	0	gewichteter Mittelwert

Tabelle 2: Parameter und Eigenschaften der implementierten Linkageverfahren

5.2.3 Eigenschaften der Standard-Linkageverfahren

Das Single-Linkage-Verfahren fügt Cluster mit einer minimalen Distanz zusammen und wird daher auch als Nearest-Neighbor-Verfahren bezeichnet. Es handelt sich um ein raumverkleinerndes Verfahren, das zum sogenannten *Chaining*-Effekt neigt. Hierbei werden einzelne Objekte oder kleinere Cluster schrittweise zu langen Clusterketten verbunden.

Das Complete-Linkage-Verfahren stellt den Gegenpol zum Single-Linkage dar, da es auf einer maximalen Distanz basiert. Es wird auch als Furthest-Neighbor-Verfahren bezeichnet. Dementsprechend verfolgt es eine raumvergrößernde Strategie, die häufig zu kompakteren und stärker voneinander getrennten Clustern führt.

Das Average-Linkage-Verfahren ist ein Beispiel für ein konservierendes Verfahren, das den Raum weder verkleinert noch vergrößert. Es basiert auf dem gewichteten Mittelwert, was alleine

durch die Parameter α_i und α_j ausgedrückt wird, während die beiden anderen Terme wegfallen. Damit stellt es einen Kompromiss zwischen Single- und Complete-Linkage dar.

5.2.4 Fazit

Diese drei implementierten Verfahren können somit als Spezialfälle der allgemeinen Lance-Williams-Funktion verstanden werden. Die benutzerdefinierte Linkagefunktion erlaubt darüber hinaus die freie Wahl der vier Parameter und damit die Implementierung weiterer hierarchischer Linkage-Verfahren.

6 Visualisierung

6.1 Heatmap

6.2 Dendrogramm

7 GUI

7.1 Serverlogik

7.2 Farben

7.2.1 Kontrast- und Wahrnehmungsanforderungen

Die visuelle Aufbereitung der komplexen Darstellungen fordert fehlerfreie Interpretierbarkeit, Barrierefreiheit, visuelle Ausgeglichenheit und Neutralität. Dadurch sollen kognitive Verzerrungen durch ungleiche Signalwirkung vermieden und die Übersichtlichkeit beibehalten werden. Um dies zu erreichen, muss sichergestellt werden, dass die Extrempunkte einer Messreihe visuell mit derselben Intensität wahrgenommen werden. Ist dies nicht gewährleistet, kann das zu klinischen Fehlinterpretationen bezüglich der Relevanz bestimmter Labels führen. Die Berücksichtigung von Sehschwächen, insbesondere der Rot-Grün-Blindheit, wurde ebenfalls einbezogen, um einen höheren Grad der Barrierefreiheit zu erlangen [2].

Diese datenbezogenen Kontraste dürfen zudem nicht mit der Grafikoberfläche konkurrieren. Aus diesem Grund wurde für das gesamte Layout der GUI ein bewusst neutrales Farbschema aus Grau-, Weiß- und Beigetönen gewählt. Diese zurückhaltenden Farben minimieren die visuelle Ermüdung bei längerer Bildschirmnutzung und stellen sicher, dass der Fokus des Anwenders unverzerrt auf den biologischen Mustern im Grafikpanel liegt [20].

Da das Dashboard primär für die Betrachtung auf Bildschirmen konzipiert ist, wurden die Farben für den dabei verwendeten additiven RGB-Farbraum ausgelegt. Für den möglichen Farbdruck der exportierten PDF-Dateien, welcher im subtraktiven CMYK-Farbraum stattfindet, muss deshalb berücksichtigt werden, dass keine exakte Farbtreue zu erwarten ist [2].

7.2.2 Farbpaletten

Für die Wahl der Farbpaletten wurden sowohl theoretische als auch subjektive Farbwahrnehmungsaspekte in Betracht gezogen. Letztendlich wurden vier Farbpaletten ausgewählt, welche sowohl für die Heatmap als auch, in leicht abgewandelter Form, für das Dendrogramm verwendet wurden. Sie werden über die R-Pakete `RColorBrewer` [7] und `viridis` [5] angesteuert.




Abbildung 2: Übersicht der vier verwendeten Farbpaletten, erzeugt mit den R-Paketen `RColorBrewer` [7] und `viridis` [5].

Palette	Typ	Einsatzzweck und Begründung
RdYlBu	Divergierend	Bietet durch das helle, gelbe Zentrum einen neutralen Mittelpunkt für zweiseitige Abweichungen. Die Unterscheidung der äußeren Maxima mit Rot und Blau sind bewusst mit annähernd gleicher visueller Intensität gewählt und gut differenzierbar für Menschen mit einer Rot-Grün-Schwäche.
RdBu	Divergierend	Ein klassisches, in der Genexpressionsanalyse bewährtes Farbschema, das maximale Kontraste liefert. Da die Palette mit Rot, Weiß und Blau auf Grünanteile verzichtet, ist sie zudem für Personen mit Rot-Grün-Schwäche gut differenzierbar.
PRGn	Divergierend	Dient als kontrastreiche Alternative zu traditionellen Skalen. Da die Unterscheidung von Violett und Grün nicht auf der Rot-Grün-Achse, sondern zusätzlich über die Blau-Gelb-Wahrnehmung erfolgt, ist die Kombination für Personen mit der deutlich häufigeren Rot-Grün-Sehschwäche gut differenzierbar.
viridis	Sequentiell	Zeichnet sich durch einen gleichmäßigen, monoton steigenden Verlauf der Luminanz (Helligkeit) aus. Die visuelle Information bleibt auch bei Konvertierung in Graustufen oder Schwarz-Weiß-Druck vollständig erhalten.

Tabelle 3: Vergleich der implementierten Farbpaletten für die Heatmap-Generierung.

Die drei divergierenden Paletten RdYlBu, RdBu und PRGn sind dabei gezielt so konstruiert, dass ihre beiden äußeren Farbwerte eine annähernd gleiche Sättigung und Helligkeit aufweisen [7]. Dadurch wird vermieden, dass eine der beiden Richtungen einer Abweichung, etwa Über- oder Unterexpression eines Gens, allein aufgrund der Farbwahl visuell stärker gewichtet oder als bedeutsamer wahrgenommen wird als die andere.

Für die Heatmap wird von den Farbpaletten jeweils der vollständige, elfstufige Verlauf verwendet, bei der farblichen Kennzeichnung der Labels im Dendrogramm ergibt sich hingegen eine andere Anforderung. Während für die Heatmap eine sequentielle bzw. divergierende Ordnung kontinuierlicher Expressionswerte abgebildet werden muss, ist für die qualitative Kennzeichnung der Patienten eine unbekannte Anzahl von diskreten Gruppen, ohne natürliche Rangfolge nötig [7]. Um ein harmonisches Bild zu erzeugen orientiert sich die Farbgebung des Dendrogramms zwar an den Farbpaletten der Heatmap, verwendet jedoch nur neun der elf Farbabstufungen, da die mittleren hellen Töne oftmals nicht zuverlässig erkennbar und unterscheidbar sind.

Da es aber durchaus vorkommen kann, dass die Anzahl der zu kennzeichnenden Labels diese neun Farben übersteigt, existiert für diesen Fall ein sogenannter `default_colors`-Vektor. Er enthält 20 gut unterscheidbare Farben. Dabei wurde auf folgende Kriterien geachtet. Es wurden kaum stark leuchtende Neonfarben verwendet, da diese bei längerer Betrachtung zu visueller Ermüdung führen und unangemessen stark hervortreten würden [20]. Pastelltöne und schwer unterscheidbare Farben wurden ebenfalls ausgeschlossen, da sie auf dem hellen GUI-Hintergrund zu wenig Kontrast bieten würden. Zusätzlich wurde die Reihenfolge der Farben in der Liste so angepasst, dass stets ein deutlicher Farbabstand zwischen zwei aufeinanderfolgenden Labels besteht, um auch bei direkt benachbarter Vergabe eine gute Unterscheidbarkeit zu gewährleisten.

```
default_colors <- c(
  "#0000FF", "#FF0000", "#00FF00", "#D60072", "#B2DF8A",
  "#005300", "#FFD300", "#0096FF", "#9B4D00", "#00FFD2",
  "#A100FA", "#7B8100", "#960000", "#00646B", "#FDBF6F",
  "#FF6C00", "#540066", "#00A278", "#000094", "#FFC0CB"
)
```

Abbildung 3: Übersicht der 20 Farben des `default_colors`-Vektors.

7.2.3 Schwierigkeiten

Gut unterscheidbare Farbpaletten zu finden, die alle Anforderungen, vor allem die der Verzerrungsfreiheit erfüllen, aber auch die `default_colors` gut unterscheidbar auszuwählen, war nicht immer leicht. Die größten fachlichen Schwierigkeiten in diesem Projekt hat mir allerdings die farbliche Darstellung des Dendrogramms bereitet. Da die Linien dort sehr dünn auf weißem Hintergrund dargestellt werden, waren helle Farben aus den ausgewählten Farbpaletten häufig nicht gut erkennbar. Deshalb mussten die Abstufungen für das Dendrogramm entsprechend angepasst werden. Dieses Problem wurde leider auch erst vergleichsweise spät im Projektverlauf sichtbar, da die konzipierte Farbgebung erst spät ins Dendrogramm eingebaut wurde. Mit dem letztendlich erzielten Ergebnis bin ich zwar zufrieden, denke aber, dass sich eine noch feinere Abstimmung hätte erarbeiten lassen, wenn die getroffenen Absprachen von Beginn an konsequenter und fristgerecht eingehalten worden wären.

Aufgabe	Zuständig	Arbeitsaufwand
Recherche Farbdarstellungen	Johanna	7 Stunden
Testen verschiedener Farbtabellen	Johanna	2 Stunden
Datenfluss-Modell erstellt	Johanna	1 Stunden
Zusammenstellen der default-colors	Johanna	1,5 Stunden
Grundlagen Kapitel Biologie verfasst	Johanna	10 Stunden
Grundlagen Kapitel Medizin verfasst	Johanna	8 Stunden
Ausarbeitung Farben verfasst	Johanna	8 Stunden
Vorbereitung Präsentation	Johanna	5 Stunden
Kommunikation zwischen den Teams	Johanna	4 Stunden
Meetings mit Adrika	Johanna	3 Stunden
Absprachen mit Visualisierungsteam	Johanna	6 Stunden
Gruppenmeetings	Johanna	19,5 Stunden

Literatur

- [1] Ana Conesa, Pedro Madrigal, Sonia Tarazona, David Gomez-Cabrero, Alejandra Cervera, Andrew McPherson, Michał W. Szczesniak, Daniel J. Gaffney, Laura L. Elo, Xuegong Zhang, and Ali Mortazavi. A survey of best practices for rna-seq data analysis. *Genome Biology*, 17(1):13, 2016.
- [2] Fabio Crameri, Grace E. Shephard, and Philip J. Heron. The misuse of colour in science communication. *Nature Communications*, 11:5444, 2020.
- [3] Dirk Eddelbuettel, Romain François, JJ Allaire, Kevin Ushey, Qiang Kou, Nathan Russell, Iñaki Ucar, Doug Bates, and John Chambers. *Rcpp: Seamless R and C++ Integration*, 2026. R package version 1.1.2.
- [4] Brian S. Everitt, Sabine Landau, Morven Leese, and Daniel Stahl. *Cluster Analysis*. Wiley, Chichester, 5 edition, 2011.
- [5] Simon Garnier, Noam Ross, Robert Rudis, Antônio P. Camargo, Marco Sciaini, and Cédric Scherer. *viridis(lite) – colorblind-friendly color maps for r*, 2024. R package.
- [6] Todd R. Golub, Donna K. Slonim, Pablo Tamayo, Christine Huard, Michelle Gaasenbeek, Jill P. Mesirov, Hilary Coller, Mignon L. Loh, James R. Downing, Michael A. Caligiuri, Clara D. Bloomfield, and Eric S. Lander. Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. *Science*, 286(5439):531–537, 1999.
- [7] Mark Harrower and Cynthia A. Brewer. Colorbrewer.org: An online tool for selecting colour schemes for maps. *The Cartographic Journal*, 40(1):27–37, 2003.
- [8] Peter Horak, Christoph Heining, Sabrina Kreutzfeldt, Barbara Hutter, Annika Mock, Hamid Höck, et al. Clinical outcomes of molecular tumor boards: a systematic review. *JCO Precision Oncology*, 5:e21000495, 2021.
- [9] Minoru Kanehisa, Yoko Sato, and Masayuki Kawashima. Kegg for taxonomy-based analysis of pathways and genomes. *Nucleic Acids Research*, 51(D1):D587–D592, 2023.
- [10] Purvesh Khatri, Marina Sirota, and Atul J. Butte. Ten years of pathway analysis: Current approaches and outstanding challenges. *PLoS Computational Biology*, 8(2):e1002375, 2012.
- [11] Kimberly R. Kukurba and Stephen B. Montgomery. Rna sequencing and analysis. *Cold Spring Harbor Protocols*, 2015(11):pdb-top083808, 2015.
- [12] G. N. Lance and W. T. Williams. A general theory of classificatory sorting strategies: I. Hierarchical systems. *The Computer Journal*, 9(4):373–380, 1967.
- [13] Tong Ihn Lee and Richard A. Young. Transcriptional regulation and its misregulation in disease. *Cell*, 152(6):1237–1251, 2013.
- [14] F. Mosele, J. Remon, J. Mateo, and et al. Recommendations for the use of next-generation sequencing (ngs) for patients with metastatic cancers: a report from the esmo precision medicine working group. *Annals of Oncology*, 31(11):1491–1505, 2020.
- [15] Shavira Narrandes and Wayne Xu. Gene expression detection assay for cancer clinical use. *Journal of Cancer*, 9(13):2249–2265, 2018.
- [16] Alicia Oshlack, Mark D. Robinson, and Matthew D. Young. From rna-seq reads to differential expression. *Genome Biology*, 11(12):220, 2010.

- [17] Julia Perera-Bel, Benjamin Hutter, Priya Balasubramanian, and et al. gmtb: A software tool for integrating tumor molecular profiles into clinical decision-making. *BMC Medical Informatics and Decision Making*, 18(1):72, 2018.
- [18] Margaret A. Shipp, Kenneth N. Ross, Pablo Tamayo, Andrew P. Weng, Jeffrey L. Kutok, Renato C. T. Aguiar, Michelle Gaasenbeek, Michael Angelo, Michael Reich, Geraldine S. Pinkus, Tapan S. Ray, Michael A. Koval, Kim W. Last, Andrew Norton, T. Andrew Lister, Jill Mesirov, Donna S. Neuberg, Eric S. Lander, Jon C. Aster, and Todd R. Golub. Diffuse large b-cell lymphoma outcome prediction by gene-expression profiling and supervised machine learning. *Nature Medicine*, 8(1):68–74, 2002.
- [19] David Tamborero, Rodrigo Dienstmann, Mohamed Rachid, and et al. Support tools to guide clinical decision-making in precision oncology: the molecular tumor board. *NPJ Precision Oncology*, 4(1):22, 2020.
- [20] Edward R. Tufte. *The Visual Display of Quantitative Information*. Graphics Press, Cheshire, CT, 1983.
- [21] Bert Vogelstein, Nickolas Papadopoulos, Victor E. Velculescu, Shibin Zhou, Luis A. Diaz, and Kenneth W. Kinzler. Cancer genome landscapes. *Science*, 339(6127):1546–1558, 2013.
- [22] Zhong Wang, Mark Gerstein, and Michael Snyder. Rna-seq: a revolutionary tool for transcriptomics. *Nature Reviews Genetics*, 10(1):57–63, 2009.