

Bericht

Alisa Pesteritz, Saliha Altan, Wiktoria Cholewa,
Dominik Falk, Andreas Kasarinow, Johanna Kleidorfer,
Adrika Narasimhan, Rosina Röckseisen

13. Juli 2026

1 Einleitung

1.0.1 Biologische Grundlagen

Was ist Genexpression und -regulation?

Was sind Pathways (KEGG)?

1.0.2 Medizinische Grundlagen

Warum sind Ärzte an der Analyse von Genexpression und -regulation interessiert?

Was ist ein Tumorboard?

1.0.3 Informatische Grundlagen

Was ist eine explorative Datenanalyse?

Was ist Clustering?

2 Arbeitseinteilung (oder sowas)

3 Pathways und Dateneinlesen

4 Normalisierung

Aufgabe	Zuständig	Arbeitsaufwand
Datenvorbereitung	Rosina	7 Stunden
Normalisierungsfunktionen	Rosina	
Distanzfunktionen	Wiktorja	
Linkagefunktionen	Rosina	
Linkagefunktionen allgemein	Wiktorja	10 Stunden
Testen	Wiktorja	20 Stunden
Besprechungen	Wiktorja	

5 Clusteranalyse

5.1 Arbeitsverteilung

Der Bereich der Clusteranalyse unterteilt sich in mehrere Unteraufgaben. Zunächst wurden die Daten auf die Weiterverarbeitung vorbereitet mit Hilfe einer Preprocessing-Funktion. Der Datensatz wurde daraufhin normalisiert, wobei unterschiedliche Normalisierungsfunktionen zur Auswahl standen. Aus dem normalisierten Datensatz wurde eine Distanzmatrix berechnet und anschließend ein Linkage-Verfahren angewendet. Dementsprechend mussten neben der Preprocessing-Funktion auch die Normalisierungs-, Distanz- und Linkage-Funktionen implementiert werden.

5.2 Berechnung der Distanzmatrix

Bei Genexpressionsdaten handelt es sich um kontinuierliche Daten, deren Abstände für gewöhnlich mit Hilfe von Distanzmaßen bestimmt werden. Durch Berechnen der zeilenweisen Distanzen δ_{ij} entsteht eine symmetrische Distanzmatrix $\mathbf{D}$, wobei $\delta_{ii} = 0$ für alle i gilt. Es muss sowohl eine Distanzmatrix für die Gene als auch für die Patienten berechnet werden. Im zweiten Fall wird der Datensatz zunächst transponiert, so dass zeilenweise gearbeitet werden kann.

Es gibt eine Vielzahl an Distanzmaßen, die verwendet werden können. In dem Projekt wurden die folgenden sechs Distanzfunktionen implementiert: euklidische Distanz, Manhattan-Distanz, Minkowski-Distanz, Canberra-Distanz, Pearson-Korrelation und Winkeldistanz (Angular Separation). Eine Übersicht der Distanzfunktionen befindet sich in Tabelle 1. Hierbei sind x_{ik} und x_{jk} jeweils die k -te Variablen der p -dimensionalen Beobachtungen der Variablen i und j . Die Auswahl entstammt Everitt et al. [1], verzichtet allerdings auf Gewichte.

Mit D5 und D6 stehen auch zwei Korrelationsmaße als Distanzfunktionen zur Verfügung. Für die Korrelation ϕ_{ij} gilt $-1 \leq \phi_{ij} \leq 1$, wobei 1 die größte positive Korrelation und -1 die größte negative Korrelation darstellt. Die Korrelation kann in eine Distanz δ_{ij} im Intervall $[0, 1]$ umgerechnet werden. Korrelationsmaße eignen sich für Daten, die auf der gleichen Skala gemessen wurden, sowie deren exakten Werte nur insofern von Interesse sind, als sie Aufschluss über das relative Profil geben. So hat z.B. die Winkeldistanz (D6) die Eigenschaft, dass nur dann eine minimale Distanz von 0 zwischen zwei Zeilen entsteht, wenn die Werte der einen Zeilen Mehrfache der Werte der anderen Zeile sind.

Im Projekt wurde eine gemeinsame Funktion für die Berechnung der Distanzmatrix in C++ implementiert. Dafür wurde ein separates Repository erschaffen. Das Paket Rcpp ermöglicht die Einbindung des C++-Codes in einer R-Umgebung. Die eigentliche Funktion heißt `dist_cpp` und bekommt drei Parameter übergeben: eine numerische Matrix `mat` (den normalisierten Datensatz), einen String `method` für das Distanzmaß, und einen Integer `p`. Letzter entspricht dem Parameter r in der Minkowski-Distanz (D3).

Nr.	Name	Funktion
D1	Euklidische Distanz	$d_{ij} = (\sum_{k=1}^p (x_{ik} - x_{jk})^2)^{1/2}$
D2	Manhattan-Distanz	$d_{ij} = \sum_{k=1}^p x_{ik} - x_{jk} $
D3	Minkowski-Distanz	$d_{ij} = (\sum_{k=1}^p x_{ik} - x_{jk} ^r)^{1/r}$
D4	Canberra-Distanz	$d_{ij} = \begin{cases} 0 & \text{wenn } x_{ik} = x_{jk} = 0 \\ \sum_{k=1}^p x_{ik} - x_{jk} / (x_{ik} + x_{jk}) & \text{sonst} \end{cases}$
D5	Pearson-Korrelation	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})(x_{jk} - \bar{x}_{j\cdot})}{[\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})^2 \sum_{k=1}^p (x_{jk} - \bar{x}_{j\cdot})^2]^{1/2}},$ $\bar{x}_{i\cdot} = \frac{1}{p} \sum_{k=1}^p x_{ik}$
D6	Winkeldistanz	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p x_{ik} x_{jk}}{(\sum_{k=1}^p x_{ik}^2 \sum_{k=1}^p x_{jk}^2)^{1/2}}$

Tabelle 1: Distanzmaße

5.3 Linkagefunktionen

Die eigentliche Clusterung erfolgt mit der Linkage-Funktion `hierarchichal_clustering`. Diese Funktion erhält als Parameter eine Distanzmatrix (Ergebnis der Distanzfunktion, siehe Kapitel 5.2), eine Methode als String, sowie eine Liste aus Parametern. Standardmäßig wird als Methode `"single"` (siehe 5.3.1) und für die Parameter `NULL` übergeben.

Das Ergebnis dieser Funktion ist eine Liste mit zwei Elementen, die für die Visualisierung der Ergebnisse benötigt werden. Das erste Element ist `matched_at`, ein Vektor, der die Werte enthält, an denen die Cluster zusammengefügt wurden. Dies entspricht der minimalen Distanz an jedem Schritt. Das zweite Element der Output-Liste ist `merge`, eine `n-1` mal 2 Matrix, die in jeder Zeile die zusammengeführten Cluster-Indizes enthält.

Als Methode stehen Single-Linkage (`"single"`), Average-Linkage (`"average"`) und Complete-Linkage (`"complete"`) zur Verfügung, sowie eine benutzerdefinierte Linkage-Funktion (`"custom"`). Diese Funktionen werden in den Folgenden Unterkapiteln erklärt.

5.3.1 Single-Linkage

Das Single-Linkage-Verfahren wird auch als Nearest-Neighbour-Verfahren bezeichnet. Um zwei Cluster zusammenzufügen, wird hierbei der Abstand zwischen ihren nächstgelegenen Elementen (den „nächsten Nachbarn“) betrachtet. Wie Lance und Williams beschreiben, weist dieses Verfahren eine Tendenz dazu auf, eine Verkettung zu bilden. In jedem Schritt der Clusterung werden größere Cluster gebildet, die sich damit anderen Clustern „nähern“; so ist es wahrschein-

licher, dass größere Cluster umso stärker wachsen und sich ausbreiten. Aus diesem Grund spricht man beim Single-Linkage-Verfahren von einer raumverkleinernden Strategie.

5.3.2 Complete-Linkage

Das Complete-Linkage-Verfahren ist gewissermaßen das Gegenstück zum Single-Linkage-Verfahren und wird auch als Furthest-Neighbour-Verfahren bezeichnet. Der Abstand zwischen zwei Clustern ist hierbei über die am weitesten voneinander gelegenen Elemente definiert. Beim Zusammenfassen zu einem Clustern hat dies den Effekt, dass sich der neue Cluster keinem anderen nähert, was das Verfahren zu einer raumausdehnenden Strategie macht.

5.3.3 Average-Linkage

Das Average-Linkage-Verfahren nutzt den Mittelwert der Cluster als Abstandsmaß. Diese Methode gilt als konservierende Strategie, da sie den Raum weder verkleinert noch vergrößert.

5.3.4 Benutzerdefinierte Linkage-Funktion

Die drei zuvor beschriebenen Methoden lassen sich mit einer einzigen Funktion abdecken, die Lance und Williams [2] in ihrem Paper vorstellten:

$$d_{hk} = \alpha_i d_{hi} + \alpha_j d_{hj} + \beta d_{ij} + \gamma |d_{hi} - d_{hj}|$$

Durch Setzen der Werte für α_i , α_j , β und γ kann die Methode exakt definiert werden. Für Single-Linkage gilt $\alpha_a = \alpha_b = 0.5$, $\beta = 0$ und $\gamma = -0.5$.

6 Visualisierung

6.1 Heatmap

6.2 Dendrogramm

7 GUI

7.1 Serverlogik

7.2 Farben

Literatur

- [1] Brian S. Everitt, Sabine Landau, Morven Leese, and Daniel Stahl. *Cluster Analysis*. Wiley, Chichester, 5 edition, 2011.
- [2] G. N. Lance and W. T. Williams. A general theory of classificatory sorting strategies: I. Hierarchical systems. *The Computer Journal*, 9(4):373–380, 1967.