

Bericht

Alisa Pesteritz, Saliha Altan, Wiktorja Cholewa,
Dominik Falk, Andreas Kasarinow, Johanna Kleidorfer,
Adrika Narasimhan, Rosina Röckseisen

13. Juli 2026

1 Einleitung

1.0.1 Biologische Grundlagen

Was ist Genexpression und -regulation?

Was sind Pathways (KEGG)?

1.0.2 Medizinische Grundlagen

Warum sind Ärzte an der Analyse von Genexpression und -regulation interessiert?

Was ist ein Tumorboard?

1.0.3 Informatische Grundlagen

Was ist eine explorative Datenanalyse?

Was ist Clustering?

2 Arbeitseinteilung (oder sowas)

3 Pathways und Dateneinlesen

4 Normalisierung

Aufgabe	Zuständig	Arbeitsaufwand
Datenvorbereitung	Rosina	7 Stunden
Normalisierungsfunktionen	Rosina	
Distanzfunktionen	Wiktorja	
Linkagefunktionen	Rosina	10 Stunden
Linkagefunktionen allgemein	Wiktorja	
Testen	Wiktorja	
Besprechungen	Wiktorja	20 Stunden

5 Clusteranalyse

5.1 Arbeitsverteilung

Der Bereich der Clusteranalyse unterteilt sich in mehrere Unteraufgaben. Zunächst wurden die Daten auf die Weiterverarbeitung vorbereitet mit Hilfe einer Preprocessing-Funktion. Der Datensatz wurde daraufhin normalisiert, wobei unterschiedliche Normalisierungsfunktionen zur Auswahl standen. Aus dem normalisierten Datensatz wurde eine Distanzmatrix berechnet und anschließend ein Linkage-Verfahren angewendet. Dementsprechend mussten neben der Preprocessing-Funktion auch die Normalisierungs-, Distanz- und Linkage-Funktionen implementiert werden.

5.2 Distanzfunktionen

Bei Genexpressionsdaten handelt es sich um kontinuierliche Daten, deren Abstände für gewöhnlich mit Hilfe von Distanzmaßen bestimmt werden. Durch Berechnen der zeilenweisen Distanzen δ_{ij} entsteht eine symmetrische Distanzmatrix $\mathbf{D}$, wobei $\delta_{ii} = 0$ für alle i gilt [1]. Es muss sowohl eine Distanzmatrix für die Gene als auch für die Patienten berechnet werden. Im zweiten Fall wird der Datensatz zunächst transponiert, so dass zeilenweise gearbeitet werden kann.

Es gibt eine Vielzahl an Distanzmaßen, die verwendet werden können. In dem Projekt wurden die folgenden sechs Distanzfunktionen implementiert: euklidische Distanz, Manhattan-Distanz, Minkowski-Distanz, Canberra-Distanz, Pearson-Korrelation und Winkeldistanz (Angular Separation). Eine Übersicht der Distanzfunktionen befindet sich in Tabelle 1. Hierbei sind x_{ik} und x_{jk} jeweils die k -te Variablen der p -dimensionalen Beobachtungen der Variablen i und j .

Die **Canberra-Distanz** ist sehr sensitiv gegenüber kleinen Veränderungen nahe $x_{ik} = x_{jk} = 0$.

Neben diesen vier generellen Distanzmaßen stehen auch zwei Korrelationsmaße als Methoden zur Verfügung. Für die Korrelation ϕ_{ij} gilt $-1 \leq \phi_{ij} \leq 1$, wobei 1 die größte positive Korrelation und -1 die größte negative Korrelation darstellt. Die Korrelation kann in eine Distanz δ_{ij} im Intervall $[0, 1]$ umgerechnet werden. Korrelationsmaße eignen sich für Daten, die auf der gleichen Skala gemessen wurden, sowie deren exakten Werte nur insofern von Interesse sind, als sie Aufschluss über das relative Profil geben.

Die **Winkeldistanz** hat die Eigenschaft, dass nur dann eine Distanz von 0 zwischen zwei Zeilen entsteht, wenn die Werte der einen Zeilen Mehrfache der Werte der anderen Zeile sind.

5.3 Linkagefunktionen

Die eigentliche Clusterung erfolgt mit Hilfe der Linkage-Funktion `hierarchical_clustering`. Diese Funktion erhält als Parameter eine Distanzmatrix, eine Methode als String, sowie eine Liste aus Parametern. Standardmäßig wird als Methode **"single"** (siehe 5.3.1) und für die Parameter NULL übergeben.

Nr.	Name	Funktion
D1	Euklidische Distanz	$d_{ij} = (\sum_{k=1}^p (x_{ik} - x_{jk})^2)^{1/2}$
D2	Manhattan-Distanz	$d_{ij} = \sum_{k=1}^p x_{ik} - x_{jk} $
D3	Minkowski-Distanz	$d_{ij} = (\sum_{k=1}^p x_{ik} - x_{jk} ^r)^{1/r}$
D4	Canberra-Distanz	$d_{ij} = \begin{cases} 0 & \text{wenn } x_{ik} = x_{jk} = 0 \\ \sum_{k=1}^p x_{ik} - x_{jk} / (x_{ik} + x_{jk}) & \text{sonst} \end{cases}$
D5	Pearson-Korrelation	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})(x_{jk} - \bar{x}_{j\cdot})}{[\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})^2 \sum_{k=1}^p (x_{jk} - \bar{x}_{j\cdot})^2]^{1/2}},$ $\bar{x}_{i\cdot} = \frac{1}{p} \sum_{k=1}^p x_{ik}$
D6	Winkeldistanz	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p x_{ik} x_{jk}}{(\sum_{k=1}^p x_{ik}^2 \sum_{k=1}^p x_{jk}^2)^{1/2}}$

Tabelle 1: Distanzmaße

Das Ergebnis dieser Funktion ist eine Liste mit zwei Elementen, die für die Visualisierung der Ergebnisse benötigt werden. Das erste Element ist `matched_at`, ein Vektor, der die Werte enthält, an denen die Cluster zusammengefügt wurden. Dies entspricht der minimalen Distanz an jedem Schritt. Das zweite Element der Output-Liste ist `merge`, eine $n-1$ mal 2 Matrix, die in jeder Zeile die zusammengeführten Cluster-Indizes enthält.

Als Methode stehen Single-Linkage ("`single`"), Average-Linkage ("`average`") und Complete-Linkage ("`complete`") zur Verfügung, sowie eine benutzerdefinierte Linkage-Funktion ("`custom`"). Diese Funktionen werden in den Folgenden Unterkapiteln erklärt.

5.3.1 Single-Linkage

Das Single-Linkage-Verfahren wird auch als Nearest-Neighbour-Verfahren bezeichnet. Um zwei Cluster zusammenzufügen, wird hierbei der Abstand zwischen ihren nächstgelegenen Elementen (den „nächsten Nachbarn“) betrachtet. Wie Lance und Williams beschreiben, weist dieses Verfahren eine Tendenz dazu auf, eine Verkettung zu bilden. In jedem Schritt der Clustering werden größere Cluster gebildet, die sich damit anderen Clustern „nähern“; so ist es wahrscheinlicher, dass größere Cluster umso stärker wachsen und sich ausbreiten. Aus diesem Grund spricht man beim Single-Linkage-Verfahren von einer raumverkleinernden Strategie.

5.3.2 Complete-Linkage

Das Complete-Linkage-Verfahren ist gewissermaßen das Gegenstück zum Single-Linkage-Verfahren und wird auch als Furthest-Neighbour-Verfahren bezeichnet. Der Abstand zwischen zwei Clustern ist hierbei über die am weitesten voneinander gelegenen Elemente definiert. Beim Zusammenfassen zu einem Clustern hat dies den Effekt, dass sich der neue Cluster keinem anderen nähert, was das Verfahren zu einer raumausdehnenden Strategie macht.

5.3.3 Average-Linkage

Das Average-Linkage-Verfahren nutzt den Mittelwert der Cluster als Abstandsmaß. Diese Methode gilt als konservierende Strategie, da sie den Raum weder verkleinert noch vergrößert.

5.3.4 Benutzerdefinierte Linkage-Funktion

Die drei zuvor beschriebenen Methoden lassen sich mit einer einzigen Funktion abdecken, die Lance und Williams [2] in ihrem Paper vorstellten:

$$d_{hk} = \alpha_i d_{hi} + \alpha_j d_{hj} + \beta d_{ij} + \gamma |d_{hi} - d_{hj}|$$

Durch Setzen der Werte für α_i , α_j , β und γ kann die Methode exakt definiert werden.

6 Visualisierung

6.1 Heatmap

6.2 Dendrogramm

7 GUI

7.1 Serverlogik

7.2 Farben

Literatur

- [1] Brian S. Everitt, Sabine Landau, Morven Leese, and Daniel Stahl. *Cluster Analysis*. Wiley, Chichester, 5 edition, 2011.
- [2] G. N. Lance and W. T. Williams. A general theory of classificatory sorting strategies: I. Hierarchical systems. *The Computer Journal*, 9(4):373–380, 1967.