

Bericht

Alisa Pesteritz, Saliha Altan, Wiktorja Cholewa,
Dominik Falk, Andreas Kasarinow, Johanna Kleidorfer,
Adrika Narasimhan, Rosina Röckseisen

16. Juli 2026

1 Einleitung

1.0.1 Biologische Grundlagen

Was ist Genexpression und -regulation?

Was sind Pathways (KEGG)?

1.0.2 Medizinische Grundlagen

Warum sind Ärzte an der Analyse von Genexpression und -regulation interessiert?

Was ist ein Tumorboard?

1.0.3 Informatische Grundlagen

Was ist eine explorative Datenanalyse?

Was ist Clustering?

2 Arbeitseinteilung (oder sowas)

3 Pathways und Dateneinlesen

4 Normalisierung

Aufgabe	Zuständig	Arbeitsaufwand
Datenvorbereitung	Rosina	7 Stunden
Normalisierungsfunktionen	Rosina	
Distanzfunktionen	Wiktorina	
Linkagefunktionen	Rosina	
Linkagefunktionen allgemein	Wiktorina	13 Stunden
Testen (inkl. GUI- und Visualisierungsfunktionen)	Wiktorina	30 Stunden
Besprechungen	Wiktorina	20 Stunden
Verwaltungsaufgaben	Wiktorina	10 Stunden

5 Clusteranalyse

5.1 Arbeitsverteilung

Der Bereich der Clusteranalyse unterteilt sich in mehrere Unteraufgaben. Zunächst wurden die Daten auf die Weiterverarbeitung vorbereitet mit Hilfe einer Preprocessing-Funktion. Der Datensatz wurde daraufhin normalisiert, wobei unterschiedliche Normalisierungsfunktionen zur Auswahl standen. Aus dem normalisierten Datensatz wurde eine Distanzmatrix berechnet und anschließend ein Linkage-Verfahren angewendet. Dementsprechend mussten neben der Preprocessing-Funktion auch die Normalisierungs-, Distanz- und Linkage-Funktionen implementiert werden.

5.2 Berechnung der Distanzmatrix

Für das Zusammenfügen der Cluster muss zunächst bestimmt werden, wie ähnlich, bzw. nah diese zueinander sind. Da es sich bei den in diesem Projekt verwendeten Genexpressionsdaten um kontinuierliche Daten handelt, wird ihre Nähe mit Hilfe von Distanzmaßen bestimmt. Für ein Distanzmaß δ_{ij} muss die Dreiecksungleichung gelten, d.h. für drei Elemente i , j und m :

$$\delta_{ij} + \delta_{im} \geq \delta_{jm}$$

Durch Berechnen der zeilenweisen Distanzen δ_{ij} , für welche diese Bedingung gilt, entsteht eine symmetrische Distanzmatrix $\mathbf{D}$, wobei $\delta_{ii} = 0$ für alle i gilt [2]. Es muss sowohl eine Distanzmatrix für die Gene als auch für die Patienten berechnet werden. Im zweiten Fall wird der Datensatz zunächst transponiert, so dass zeilenweise gearbeitet werden kann.

Es gibt eine Vielzahl an Distanzmaßen, die verwendet werden können. In dem Projekt wurden die folgenden sechs Distanzfunktionen implementiert: euklidische Distanz, Manhattan-Distanz, Minkowski-Distanz, Canberra-Distanz, Pearson-Korrelation und Winkeldistanz (Angular Separation). Eine Übersicht der Distanzfunktionen befindet sich in Tabelle 1. Hierbei sind x_{ik} und x_{jk} jeweils die k -te Variablen der p -dimensionalen Beobachtungen der Variablen i und j . Die Auswahl entstammt Everitt et al. [2], verzichtet allerdings auf Gewichte.

Die euklidische Distanz (D1) gilt häufig als das gängigste Distanzmaß. Sie hat die Eigenschaft, dass die berechnete Distanz als ein Abstand zwischen zwei Punkten im p -dimensionalen Raum verstanden werden kann [2]. Die Manhattan-Distanz (D2) ist ähnlich, definiert den Abstand allerdings ausschließlich über geradlinige Verbindungen. D1 und D2 sind Spezialfälle der Minkowski-Distanz (D3), für $r = 2$, bzw. $r = 1$. Dem Nutzer wird bei Auswahl von D3 die Möglichkeit gegeben, einen eigenen Wert für r einzugeben, wobei Werte < 1 nicht zulässig sind. Die Canberra-Distanz (D4) ist besonders sensitiv für kleine Veränderungen nahe 0 [2].

Mit D5 und D6 stehen auch zwei Korrelationsmaße als Distanzfunktionen zur Verfügung. Für die Korrelation ϕ_{ij} gilt $-1 \leq \phi_{ij} \leq 1$, wobei 1 die größte positive Korrelation und -1 die größte

negative Korrelation darstellt. Die Korrelation kann in eine Distanz δ_{ij} im Intervall $[0, 1]$ umgerechnet werden. Korrelationsmaße eignen sich für Daten, die auf der gleichen Skala gemessen wurden, sowie deren exakten Werte nur insofern von Interesse sind, als sie Aufschluss über das relative Profil geben. So hat z.B. die Winkeldistanz (D6) die Eigenschaft, dass nur dann eine minimale Distanz von 0 zwischen zwei Zeilen entsteht, wenn die Werte der einen Zeilen Mehrfache der Werte der anderen Zeile sind.

Im Projekt wurde eine gemeinsame Funktion für die Berechnung der Distanzmatrix in C++ implementiert. Dafür wurde ein separates Repository erschaffen. Das Paket `Rcpp` [1] ermöglicht die Einbindung des C++-Codes in eine R-Umgebung. Die eigentliche Funktion heißt `dist_cpp` und bekommt drei Parameter übergeben: eine numerische Matrix `mat` (den normalisierten Datensatz), einen String `method` für das gewählte Distanzmaß, und einen Integer `p`. Letzter entspricht dem Parameter r in der Minkowski-Distanz (D3). Die Implementierung entspricht den mathematischen Formeln und ist entsprechend einfach.

Nr.	Name	Funktion
D1	Euklidische Distanz	$d_{ij} = (\sum_{k=1}^p (x_{ik} - x_{jk})^2)^{1/2}$
D2	Manhattan-Distanz	$d_{ij} = \sum_{k=1}^p x_{ik} - x_{jk} $
D3	Minkowski-Distanz	$d_{ij} = (\sum_{k=1}^p x_{ik} - x_{jk} ^r)^{1/r}$ mit $r \geq 1$
D4	Canberra-Distanz	$d_{ij} = \begin{cases} 0 & \text{wenn } x_{ik} = x_{jk} = 0 \\ \sum_{k=1}^p x_{ik} - x_{jk} / (x_{ik} + x_{jk}) & \text{sonst} \end{cases}$
D5	Pearson-Korrelation	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})(x_{jk} - \bar{x}_{j\cdot})}{[\sum_{k=1}^p (x_{ik} - \bar{x}_{i\cdot})^2 \sum_{k=1}^p (x_{jk} - \bar{x}_{j\cdot})^2]^{1/2}},$ $\bar{x}_{i\cdot} = \frac{1}{p} \sum_{k=1}^p x_{ik}$
D6	Winkeldistanz	$\delta_{ij} = \frac{1 - \phi_{ij}}{2},$ $\phi_{ij} = \frac{\sum_{k=1}^p x_{ik}x_{jk}}{(\sum_{k=1}^p x_{ik}^2 \sum_{k=1}^p x_{jk}^2)^{1/2}}$

Tabelle 1: Distanzmaße

5.3 Linkagefunktionen

Die eigentliche Clusterung erfolgt mit der Linkage-Funktion `hierarchichal_clustering`. Diese Funktion erhält als Parameter eine Distanzmatrix `d_mat` (siehe Kapitel 5.2), den Namen des gewünschten Linkage-Verfahrens `method` als String, sowie optional eine Liste mit vier Parametern `custom_params`. Standardmäßig wird als Methode `"single"` und für die Parameter `NULL` übergeben.

Das Ergebnis dieser Funktion ist eine Liste mit zwei Elementen, die für die Visualisierung der Ergebnisse benötigt werden. Das erste Element ist `matched_at`, ein Vektor, der die Werte enthält, an denen die Cluster zusammengefügt wurden. Dies entspricht der minimalen Distanz an jedem Schritt. Das zweite Element der Output-Liste ist `merge`, eine $n - 1$ mal 2 Matrix, die in jeder Zeile die zusammengeführten Cluster-Indizes enthält.

Als Methoden stehen Single-Linkage (`single`), Average-Linkage (`average`) und Complete-Linkage (`complete`), sowie eine benutzerdefinierte Linkage-Funktion (`custom`) zur Verfügung. Nach jeder Zusammenführung zweier Cluster wird die Distanzmatrix entsprechend der gewählten Linkage-Methode aktualisiert.

5.3.1 Linkagefunktion nach Lance-Williams

Die Methode `custom` implementiert die allgemeine Formel von Lance und Williams [3]. Werden zwei Cluster i und j zu einem neuen Cluster k zusammengefasst, so kann die Distanz des neuen Clusters k zu einem weiteren Cluster h durch diese Funktion aktualisiert werden:

$$d_{hk} = \alpha_i d_{hi} + \alpha_j d_{hj} + \beta d_{ij} + \gamma |d_{hi} - d_{hj}|$$

Die vier Parameter α_i , α_j , β und γ bestimmen die Aktualisierung der Distanz. Erst ihre jeweilige Kombination definiert ein konkretes Linkage-Verfahren, wie Single-, Complete- oder Average-Linkage. Tabelle 2 enthält eine Übersicht der erforderlichen Parameter für diese drei Standardverfahren.

Die Implementierung basiert vollständig auf dieser allgemeinen Formel. Dadurch kann die Aktualisierung der Distanzmatrix unabhängig vom konkreten Linkage-Verfahren mit derselben Implementierung erfolgen; lediglich die Parameter unterscheiden sich zwischen den Verfahren. Für die Methoden `single`, `average` und `complete` werden die zugehörigen Parameter automatisch gesetzt. Wird hingegen `custom` gewählt, müssen die vier Parameter vom Benutzer über die Eingabemaske angegeben werden. Die Eingabe wird lediglich auf numerische Werte überprüft. Dynamische Ausdrücke wie n_i/n_k , die beispielsweise für Average-Linkage verwendet werden, können daher nicht angegeben werden. Ebenso erfolgt keine Überprüfung hinsichtlich der theoretischen Sinnhaftigkeit der gewählten Parameter.

5.3.2 Bedeutung der Parameter

Die Parameter α_i und α_j gewichten den Beitrag der ursprünglichen Cluster i und j auf die neue Distanz d_{hk} . Gilt $\alpha_i = \alpha_j$, so werden beide Cluster gleich gewichtet, wie es bei Single- und Complete-Linkage der Fall ist. Beim Average-Linkage-Verfahren werden die Gewichte proportional zu der jeweiligen Clustergröße gewählt. Hierbei entsprechen n_i und n_j jeweils der Anzahl der Elemente im Cluster i , bzw. j . Es gilt $n_k = n_i + n_j$.

Der Parameter β gewichtet zusätzlich die Distanz d_{ij} zwischen den beiden zusammengeführten Clustern. Dadurch kann die Lage der neu berechneten Distanz beeinflusst werden. Für die drei implementierten Standardverfahren gilt $\beta = 0$, daher wirkt sich der Term nicht auf das Ergebnis aus. Lance und Williams diskutieren jedoch die zentrale Rolle dieses Parameters in der sogenannten *Flexiblen Strategie*, wobei β im Bereich $-1 \leq \beta < 1$ betrachtet wird, so dass weitere Linkage-Verfahren entstehen.

Der Parameter γ gewichtet die absolute Differenz zwischen d_{hi} und d_{hj} . Für die Werte $\gamma = -0,5$, bzw. $\gamma = 0,5$ reduziert sich die Lance-Williams-Formel auf das Minimum, bzw. das Maximum der beiden Distanzen. Dadurch erhält man unmittelbar Single-Linkage, bzw. Complete-Linkage. Für $\gamma = 0$ hingegen entfällt dieser Term vollständig, wie es z.B. beim Average-Linkage der Fall ist.

Linkage-Verfahren	α_i	α_j	β	γ	Eigenschaft
Single-Linkage	0,5	0,5	0	-0,5	Minimum
Complete-Linkage	0,5	0,5	0	0,5	Maximum
Average-Linkage	n_i/n_k	n_j/n_k	0	0	gewichteter Mittelwert

Tabelle 2: Parameter der implementierten Linkageverfahren

5.3.3 Eigenschaften der Standard-Linkageverfahren

Das Single-Linkage-Verfahren fügt Cluster mit einer minimalen Distanz zusammen und wird daher auch als Nearest-Neighbor-Verfahren bezeichnet. Es handelt sich um ein raumverkleinern- des Verfahren, das zum sogenannten *Chaining*-Effekt neigt. Hierbei werden einzelne Objekte oder kleinere Cluster schrittweise zu langen Clusterketten verbunden.

Das Complete-Linkage-Verfahren stellt den Gegenpol zum Single-Linkage dar, da es auf einer maximalen Distanz basiert. Es wird auch als Furthest-Neighbor-Verfahren bezeichnet. Dement- sprechend verfolgt es eine raumvergrößernde Strategie, die häufig zu kompakteren und stärker voneinander getrennten Clustern führt.

Das Average-Linkage-Verfahren ist ein Beispiel für ein konservierendes Verfahren, das den Raum weder verkleinert noch vergrößert. Es basiert auf dem gewichteten Mittelwert, was alleine durch die Parameter α_i und α_j ausgedrückt wird, während die beiden anderen Terme wegfallen. Da- mit stellt es einen Kompromiss zwischen Single- und Complete-Linkage dar.

Diese drei implementierten Verfahren können somit als Spezialfälle der allgemeinen Lance- Williams-Funktion verstanden werden. Die benutzerdefinierte Linkagefunktion erlaubt darüber hinaus die freie Wahl der vier Parameter und damit die Implementierung weiterer hierarchischer Linkage-Verfahren.

6 Visualisierung

6.1 Heatmap

6.2 Dendrogramm

7 GUI

7.1 Serverlogik

7.2 Farben

Literatur

- [1] Dirk Eddelbuettel, Romain François, JJ Allaire, Kevin Ushey, Qiang Kou, Nathan Russell, Iñaki Ucar, Doug Bates, and John Chambers. *Rcpp: Seamless R and C++ Integration*, 2026. R package version 1.1.2.
- [2] Brian S. Everitt, Sabine Landau, Morven Leese, and Daniel Stahl. *Cluster Analysis*. Wiley, Chichester, 5 edition, 2011.
- [3] G. N. Lance and W. T. Williams. A general theory of classificatory sorting strategies: I. Hierarchical systems. *The Computer Journal*, 9(4):373–380, 1967.